

Schistosoma

Групповой проект №7

Баранова Мария
Токарев Алексей
Ветошкина Ирина
Бойко Евгений
Мельников Вадим
Кудряшов Алексей
Кривощёков Андрей
Кузьмин Василий


Образцы

Участник	Организм	Название генома	Длина	Число генов
Баранова Мария	Spindale	GCA_946903255.1	390.1 Mb	9330
Токарев Алексей	Bovis	GCA_944470425.2	391.8 Mb	9589
Ветошкина Ирина	Japonicum	GCA_021461655.1	408.5 Mb	9769
Бойко Евгений	Mattheei	GCA_944470405.2	389.3 Mb	10,771
Мельников Вадим	Haematobium	GCF_000699445.3	400.3 Mb	9428
Кудряшов Алексей	Guineensis	GCA_944470375.2	379.3 Mb	9715
Кривощёков Андрей	Mekongi	GCA_034768735.1	404.2 Mb	9094
Кузьмин Василий	Intercalatum	GCA_944470365.2	386.1 Mb	9676


Что было сделано

- Поиск генов, отвечающих за эпигенетику с помощью hmmscan с E-value $\leq 1e-5$
- Аннотация вторичных структур с помощью следующих инструментов:
- ZHunt (многопоточный zhunt.rs) с размером окна - 12, минимальным размером - 8 и максимальным - 12. С отфильтровыванием по Z-score > 400
- ZDNABERT с моделью HG kouzine, порогом уверенности модели 0.5 и минимальной длиной последовательности 10
- Квадруплексов по шаблону $G\{3,5\}[ATGC]\{1,7\}\{3,\}G\{3,5\}$ на обоих стрендах

Распределение структур



Распределение структур



Гены, отвечающие за эпигенетику

CTCF и белков когезинового комплекса не нашлось,
поэтому были выбраны:

- Chromo domain
- DNA_methylase (C5 cytosine-MTase)
- Histone deacetylase (HDAC)
- JmjC (histone demethylase)
- MBT
- PHD finger
- SIR2 (NAD-dep. deacetylase)
- Bromodomain

Для выравниваний использовалась программа MAFFT с параметром –auto. Деревья строили с помощью метода максимального правдоподобия в программе FastTree. Сделали 1000 бутстрэп-повторов для надежности. На деревьях мы показали только те ветки, которые оказались надежными с вероятностью не меньше 90%.

Schistosoma intercalatum

Кузьмин Василий

- Exons — наиболее обеднённый регион для всех трёх типов структур (особенно для ZDNABERT)
- Downstream (200 bp) уникально обогащён квадруплексами, но обеднён Z-ДНК
- Promoters почти всегда обеднены (кроме ZHunt, где близко к фону)
- Introns и Intergenic — основные расположения для всех структур, особенно для Z-ДНК

Семейство	
PHD finger	54
SNF2_N (chromatin remodeler ATPase)	43
SET (histone lysine methyltransferase)	29
Bromodomain	22
Chromo domain	20
JmJc (histone demethylase)	19
Histone deacetylase (HDAC)	17
PWWP	11
MBT	10
Acetyltransferase (GNAT)	9
SIR2 (NAD-dep. deacetylase)	7
JmJN	6
MOZ/SAS (HAT, MYST)	5
Tudor	5
Pre-SET	4
MBD (methyl-CpG binding)	2
zf-CXXC	2
DNA_methylase (C5 cytosine-MTase)	1



	Region	n_regions_total	quadruplex_n_regions_hit	quadruplex_frac_regions_hit	zhunt_n_regions_hit	zhunt_frac_regions_hit	zdnabert_n_regions_hit	zdnabert_frac_regions_hit
0	Exons	75411	68	0.0009	2196	0.0291	190	0.0025
1	Introns	66507	518	0.0078	16806	0.2527	6705	0.1008
2	Promoters (1000 up from TSS)	9271	33	0.0036	1367	0.1474	337	0.0363
3	Downstream (200 bp)	9372	22	0.0023	302	0.0322	50	0.0053
4	Intergenic	8911	547	0.0614	6449	0.7237	3594	0.4033

	Region	region_bp	bg_fraction	quadruplex_count	quadruplex_fraction	quadruplex_enrichment_vs_bg	zhunt_count	zhunt_fraction	zhunt_enrichment_vs_bg	zdnabert_count	zdnabert_fraction	zdnabert_enrichment_vs_bg
0	Exons	24729451	0.065105	70	0.0412	0.63	2549	0.0384	0.59	223	0.0116	0.18
1	Introns	177993139	0.468602	761	0.4479	0.96	30829	0.4648	0.99	9433	0.4902	1.05
2	Promoters (1000 up from TSS)	9393419	0.024730	35	0.0206	0.83	1548	0.0233	0.94	358	0.0186	0.75
3	Downstream (200 bp)	1883222	0.004958	22	0.0129	2.61	311	0.0047	0.95	53	0.0028	0.56
4	Intergenic	177115634	0.466292	875	0.5150	1.10	33177	0.5002	1.07	9589	0.4983	1.07

Chromo domain


Консервативный белковый домен, участвующий в: распознавании метилированных гистонов, регуляции структуры хроматина, эпигенетическом контроле экспрессии генов, процессах развития и дифференцировки клеток

- Множество дискретных групп, клад белков
- Внутри групп сильно похожи, но при этом сами группы сильно дивергированы
- Отсутствие видовых клад и схожесть генов у различных видов говорит об ортологии генов
- Короткие ветви внутри клад также подтверждают высокую консервативность этих генов



Schistosoma Bovis

Токарев Алексей Михайлович



hmsscan: 320 генов, 18 семейств

Топ-3:

- PHD finger (50 генов)
- SET-домен (46)
- SNF2_N (44)

Интересное из распределения структур:

- x3.1 квадруплексов в Downstream
- x0.8 квадруплексов в экзонах/интронах
- 15%+ промоторов содержат Z-ДНК
- Остальное +- равномерно

2а. Доля структур, попавших в каждый тип региона


Регион	Охват, bp	Доля от генома	Число квадруплексов	Доля квадруплексов	Enrichment vs bg	Chi
Exons	28,442,251	0.073709	86	0.0613	0.83	28
Introns	176,082,946	0.456327	514	0.3664	0.8	30
Promoters (1000 up from TSS)	9,305,053	0.024114	36	0.0257	1.06	15
Downstream (200 bp)	1,866,067	0.004836	21	0.015	3.1	37
Intergenic	181,546,084	0.470485	804	0.5731	1.22	35

Schistosoma Mekongi

Кривощёков Андрей

Регион	G4 count	G4 frac	G4 enrich	ZHUNT count	ZHUNT frac	ZHUNT enrich	BERT count	BERT frac	BERT enrich
Exons	16	0.0054	0.13	1 167	0.0287	0.66	91	0.0162	0.37
Introns	1065	0.3622	0.85	17 513	0.4314	1.01	1926	0.3425	0.80
Promoters	74	0.0252	1.10	1 075	0.0265	1.16	108	0.0192	0.84
Downstream	22	0.0075	1.63	240	0.0059	1.29	6	0.0011	0.23
Intergenic	1860	0.6327	1.20	22 131	0.5451	1.03	3609	0.6417	1.21

Регион генома	Всего регионов	G4 hits	G4 % hit	ZHUNT hits	ZHUNT % hit	BERT hits	BERT % hit
Exons	68 083	16	0.02%	1 139	1.67%	89	0.13%
Introns	59 371	950	1.60%	11 595	19.53%	1 592	2.68%
Promoters	8 591	68	0.79%	969	11.28%	97	1.13%
Downstream	8 650	22	0.25%	235	2.72%	6	0.07%
Intergenic	8 720	1 108	12.71%	5 898	67.64%	1 907	21.87%






- Протеом: с помощью hmmscan идентифицировано 18 эпигенетических семейств (110+ генов). Лидеры — PHD finger (30 генов) и SNF2_N (22 гена).
- Вторичные структуры: после похромосомного объединения интервалов (merge) обнаружено ~42 000 чистых Z-регионов по ZHUNT и ~5 700 по ZDNABERT.
- Эволюционный тренд: наблюдается сильнейший в группе сигнал негативного отбора в экзонах (обогащение G4 — 0.13, Z-ДНК — 0.66).

DNMT

Кривощёков Андрей

DNA_methylase (C5 cytosine-MTase) — это эволюционно древнее семейство ДНК-метилтрансфераз эукариот. Ферменты этого семейства катализируют перенос метильной группы на цитозин (C), отвечая за долговременное выключение генов и быструю адаптацию организма к смене среды. ДНК-метилазы обнаружены у всех групп эукариот — от одноклеточных водорослей до растений, беспозвоночных и человека.



Schistosoma mattheei

Бойко Евгений


- 350 попаданий в эпиген. домен (hmmscan), 196 уникальных белков
- 18/19 семейств (Tet_JBP не представлен)
- лидеры по семействам те же, что и у близкие видов
- подтверждение гипотезы о распределении G4
- высокое обогащение G4 в downstream (200 bp)
- Z-ДНК покрывает 67% межгенных областей, сильный недостаток в экзонах

	Region	region_bp	bg_fraction	quadruplex_count	quadruplex_fraction	quadruplex_enrichment_vs_bg	zhunt_count	zhunt_fraction	zhunt_enrichment_vs_bg
0	Exons	23870386	0.061308	57	0.0507	0.83	2376	0.0350	0.57
1	Introns	175622123	0.451063	476	0.4235	0.94	30363	0.4478	0.99
2	Promoters (1000 up from TSS)	11504789	0.029549	30	0.0267	0.90	1895	0.0280	0.95
3	Downstream (200 bp)	2458551	0.006314	16	0.0142	2.25	415	0.0061	0.97
4	Intergenic	189880685	0.487685	596	0.5302	1.09	35260	0.5201	1.07

Acetyltransferase_Smattheei.faa (белков: 13)
Bromodomain_Smattheei.faa (белков: 18)
Chromo_Smattheei.faa (белков: 16)
DNA_methylase_Smattheei.faa (белков: 3)
HDAC_Smattheei.faa (белков: 8)
JmjC_Smattheei.faa (белков: 10)
JmjN_Smattheei.faa (белков: 5)
MBD_Smattheei.faa (белков: 2)
MBT_Smattheei.faa (белков: 4)
MOZ_SAS_Smattheei.faa (белков: 10)
PHD_Smattheei.faa (белков: 39)
PWWP_Smattheei.faa (белков: 5)
Pre-SET_Smattheei.faa (белков: 3)
SET_Smattheei.faa (белков: 21)
SIR2_Smattheei.faa (белков: 7)
SNF2_N_Smattheei.faa (белков: 26)
Tudor_Smattheei.faa (белков: 5)
zf-CXXC_Smattheei.faa (белков: 1)

	Region	n_regions_total	quadruplex_n_regions_hit	quadruplex_frac_regions_hit	zhunt_n_regions_hit	zhunt_frac_regions_hit
0	Exons	77751	55	0.0007	2047	0.0263
1	Introns	67495	432	0.0064	16602	0.2460
2	Promoters (1000 up from TSS)	11134	30	0.0027	1666	0.1496
3	Downstream (200 bp)	11994	16	0.0013	400	0.0334
4	Intergenic	10352	463	0.0447	6930	0.6694

SIR2



SIR2 (сиртуин) – фермент, который удаляет ацетильные группы с остатков лизина в гистонах и других белках, используя NAD^+ в качестве кофактора, и участвует в регуляции старения, метаболизма и экспрессии генов.

Дерево изоморфно некоторым другим доменным деревьям, например HDAC и частично MBT, что говорит об их коэволюционной природе

Schistosoma haematobium

- Было найдено 1146 квадруплексов
- Большинство из них в интронах и межгенниках
- Большинство распределены примерно как фон
- Есть заметное обогащение квадруплексов в downstream, но их число мало
- Z-ДНК обеднена в экзонах
- Для работы с гистонами представлено много генов (PHD finger, SNF2_N, SET), для метилирования – мало (DNA_methylase, MBD, zf-CXXC)

	Region	regions_total	quadruplex_n_regions_hit	quadruplex_frac_regions_hit	zhunt_n_regions_hit	zhunt_frac_regions_hit	zdnabert_n_regions_hit	zdnabert_frac_regions_hit
0	Exons	73770	121	0.0016	588	0.0080	809	0.0110
1	Introns	65149	416	0.0064	2074	0.0318	6377	0.0979
2	Promoters (1000 up from TSS)	8989	22	0.0024	87	0.0097	373	0.0415
3	Downstream (200 bp)	8916	12	0.0013	27	0.0030	77	0.0086
4	Intergenic	8628	394	0.0457	1335	0.1547	3530	0.4091


	Region	region_bp	bg_fraction	quadruplex_count	quadruplex_fraction	quadruplex_enrichment_vs_bg	zhunt_count	zhunt_fraction	zhunt_enrichment_vs_bg	zdnabert_count	zdnabert_fraction	zdnabert_enrichment_vs_bg
0	Exons	43445182	0.110806	128	0.1117	1.01	689	0.1233	1.11	983	0.0479	0.43
1	Introns	170842474	0.435731	448	0.3909	0.90	2666	0.4769	1.09	8918	0.4348	1.00
2	Promoters (1000 up from TSS)	9111355	0.023238	26	0.0227	0.98	104	0.0186	0.80	402	0.0196	0.84
3	Downstream (200 bp)	1809508	0.004615	12	0.0105	2.27	34	0.0061	1.32	79	0.0039	0.83
4	Intergenic	177794493	0.453462	572	0.4991	1.10	2322	0.4154	0.92	10619	0.5177	1.14

Семейство	Число генов
PHD finger	36
SNF2_N (chromatin remodeler ATPase)	30
SET (histone lysine methyltransferase)	20
Acetyltransferase (GNAT)	17
Chromo domain	17
Bromodomain	15
JmjC (histone demethylase)	10
Histone deacetylase (HDAC)	10
PWWP	8
MBT	7
MOZ/SAS (HAT, MYST)	6
SIR2 (NAD-dep. deacetylase)	5
DNA_methylase (C5 cytosine-MTase)	3
JmjN	3
Tudor	3
Pre-SET	3
MBD (methyl-CpG binding)	2
zf-CXXC	2

HDAC

HDAC – ферменты, которые убирают ацетильные группы с остатков лизина в хвостах

FACTOIDS




- Почти все клады содержат все рассматриваемые виды, в каждой высокие апостериорные вероятности
-> расхождение, породившее подтипы HDAC древнее, чем расхождение видов *Schistosoma*
- Из длин ветвей следует, что большинство подтипов HDAC консервативны

Shistosoma japonicum

Ветошкина Ирина

Хромосомы





Семейство	103
SNF2_N (chromatin remodeler ATPase)	71
Bromodomain	57
SET (histone lysine methyltransferase)	49
PHD finger	34
MBT	32
Chromo domain	24
JmjC (histone demethylase)	19
SIR2 (NAD-dep. deacetylase)	17
Histone deacetylase (HDAC)	16
Acetyltransferase (GNAT)	14
PWWP	9
MOZ/SAS (HAT, MYST)	7
MBD (methyl-CpG binding)	5
DNA_methylase (C5 cytosine-MTase)	4
JmjN	3
Pre-SET	2
Tudor	1
zf-CXXC	1

	Region	n_regions_total	quadruplex_n_regions_hit	quadruplex_frac_regions_hit	zhunt_n_regions_hit	zhunt_frac_regions_hit	zdnabert_n_regions_hit	zdnabert_frac_regions_hit
0	Exons	77232	81	0.0010	414	0.0054	21	0.0003
1	Introns	67786	731	0.0108	1322	0.0195	76	0.0011
2	Promoters (1000 up from TSS)	9370	46	0.0049	86	0.0092	13	0.0014
3	Downstream (200 bp)	9378	18	0.0019	22	0.0023	1	0.0001
4	Intergenic	8785	898	0.1022	669	0.0762	133	0.0151

	Region	region_bp	bg_fraction	quadruplex_count	quadruplex_fraction	quadruplex_enrichment_vs_bg	zhunt_count	zhunt_fraction	zhunt_enrichment_vs_bg	zdnabert_count	zdnabert_fraction	zdnabert_enrichment_vs_bg
0	Exons	34728087	0.088543	82	0.0314	0.35	3532	0.1027	1.16	22	0.0651	0.74
1	Introns	156860111	0.399934	779	0.2979	0.74	14572	0.4239	1.06	85	0.2515	0.63
2	Promoters (1000 up from TSS)	9443428	0.024077	49	0.0187	0.78	699	0.0203	0.84	13	0.0385	1.60
3	Downstream (200 bp)	1887976	0.004814	18	0.0069	1.43	114	0.0033	0.69	1	0.0030	0.61
4	Intergenic	200804722	0.511976	1755	0.6711	1.31	16644	0.4841	0.95	232	0.6864	1.34

MBT

Ветошкина Ирина



В выделенных областях расположены виды, обитающие в Азии, остальные виды обитают в Африке.

Белки семейства MBT служат «считывателями хроматина» (chromatin readers) — они распознают определенные метки (например, метилирование) на гистонах, вокруг которых намотана ДНК. Это позволяет регулировать работу других генов, уплотняя или распуская участки хроматина.

PHD

Баранова Мария

PHD — это цинк-пальцевый домен размером 50-80 аминокислот. PHD домен работает как молекулярный считыватель эпигенетических меток. Его основная мишень — триметилирование четвёртого лизина на гистоне H3 (H3K4me3). Эта метка характерна для промоторов. PHD домены обнаружены у всех групп эукариот — от одноклеточных дрожжей до растений и человека.

Результаты выравнивания:

Выравнивание белков PHD демонстрирует высокую степень консервативности на уровне N-концевого домена.

Результаты построения дерева:

По результатам заметно, что представители африканских и азиатских видов находятся вперемешку, в большинстве клад встречаются последовательности нескольких видов.

Это говорит о том, что для семейства PHD географическое происхождение видов не является главным фактором, определяющим структуру дерева.

Вывод

В ходе групповой аналитической работы было проведено сравнительное исследование эпигенетических белков и вторичных структур ДНК у нескольких видов шистосом. Построенные филогенетические деревья для разных эпигенетических семейств оказались изоморфными, что указывает на совместную эволюцию этих систем. Анализ распределения G-квадруплексов и Z-ДНК показал их преимущественную локализацию в межгенных регионах и избегание экзонов, что согласуется с регуляторной ролью этих структур.

На основе полученных данных изученные виды были чётко разделены на африканскую и азиатскую эволюционные группы. Эпигенетический аппарат всех организмов включает основные семейства пишущие, читающие и стирающие гистоновые метки.

В целом, результаты свидетельствуют, что ключевые эпигенетические механизмы и вторичные структуры ДНК возникли уже у ранних многоклеточных, а последующая дивергенция привела к формированию отдельных филогеографических линий шистосом.

Спасибо за внимание